

PoisonedRAG 本机完整复现实验报告

日期：2026-07-07。范围：论文级复现、低投毒率实验、corpus-level true ASR、改进毒文档评估；不含最终 slide deck。

结论摘要

- 完成 paper-style、candidate-pool、corpus-level 三个实验块的 3 数据集 x 3 LLM 矩阵。
- candidate-pool 详细矩阵 153 行；corpus-level true ASR 详细矩阵 81 行；paper-style 复现矩阵 9 行。
- 所有核心指标均有三数据集 x 三 LLM 图：ASR、正确答案率、检索成功率、top-5 毒文档数量、top-5 毒文档占比。
- query-first 改进版更自然，但没有稳定超过 original；当前 original 仍是最稳 baseline。


数据矩阵完整性

实验块	矩阵定义	实际行数
Paper-style	3 datasets x 3 LLMs	9
Candidate-pool	3 datasets x 3 LLMs x (clean + 4 variants x 4 rates)	153
Corpus-level	3 datasets x 3 LLMs x (clean + 2 variants x 4 true rates)	81

Paper-style 复现矩阵

Dataset	LLM	ASR	Precision	Recall	F1
NQ	qwen3.5:9b	0.98	0.96	0.96	0.96
NQ	llama3.1:8b	0.97	0.96	0.96	0.96
NQ	mistral:7b	1.00	0.96	0.96	0.96
HotpotQA	qwen3.5:9b	1.00	1.00	1.00	1.00
HotpotQA	llama3.1:8b	0.98	1.00	1.00	1.00
HotpotQA	mistral:7b	0.99	1.00	1.00	1.00
MS MARCO	qwen3.5:9b	0.92	0.89	0.89	0.89
MS MARCO	llama3.1:8b	0.91	0.89	0.89	0.89
MS MARCO	mistral:7b	0.94	0.89	0.89	0.89

Paper-style PoisonedRAG reproduction: 3 datasets x 3 LLMs




Candidate-pool 核心 ASR 摘要

完整 153 行矩阵在 `tables/candidate_pool_full_matrix_summary.csv`; 下表只抽取 clean、1%、10% 的 ASR 方便快速阅读。


Dataset	LLM	Clean	Orig 1%	QF 1%	Orig 10%	QF 10%
NQ	qwen3.5:9b	0.04	0.78	0.76	1.00	0.98
NQ	llama3.1:8b	0.00	0.64	0.66	0.96	0.94
NQ	mistral:7b	0.06	0.62	0.66	1.00	0.92
HotpotQA	qwen3.5:9b	0.10	0.70	0.80	1.00	0.98
HotpotQA	llama3.1:8b	0.12	0.70	0.80	0.96	0.94
HotpotQA	mistral:7b	0.18	0.74	0.78	1.00	1.00
MS MARCO	qwen3.5:9b	0.10	0.84	0.84	0.92	0.94
MS MARCO	llama3.1:8b	0.08	0.58	0.66	0.92	0.94
MS MARCO	mistral:7b	0.10	0.72	0.74	1.00	0.96

Candidate-pool ASR


Candidate-pool ASR: 3 datasets x 3 LLMs x 4 variants




Candidate-pool 正确答案率




Candidate-pool 检索成功率




Candidate-pool top-5 毒文档数量



Candidate-pool top-5 毒文档占比



Candidate-pool clean baseline




Corpus-level true ASR 核心摘要

完整 81 行矩阵在 tables/corpus_level_full_matrix_summary.csv; qwen3.5 和 llama3.1 使用 ultrafast profile, mistral 使用 fast profile。


Dataset	LLM	Clean	Orig 0.0001%	QF 0.0001%	Orig 0.005%	QF 0.005%
NQ	qwen3.5:9b	0.00	0.76	0.08	0.84	0.14
NQ	llama3.1:8b	0.00	0.84	0.12	0.84	0.08
NQ	mistral:7b	0.02	0.92	0.90	0.96	0.92
HotpotQA	qwen3.5:9b	0.06	0.82	0.22	0.72	0.16
HotpotQA	llama3.1:8b	0.04	0.80	0.28	0.58	0.26
HotpotQA	mistral:7b	0.16	0.98	1.00	0.98	0.98
MS MARCO	qwen3.5:9b	0.04	0.12	0.10	0.08	0.12
MS MARCO	llama3.1:8b	0.04	0.06	0.04	0.04	0.06
MS MARCO	mistral:7b	0.08	0.98	1.00	1.00	1.00

Corpus-level true ASR


Corpus-level true ASR: 3 datasets x 3 LLMs x 2 variants




Corpus-level 正确答案率



Corpus-level 检索成功率




Corpus-level top-5 毒文档数量




Corpus-level top-5 毒文档占比

Corpus-level average poison share in retrieved top-5



Corpus-level clean baseline



结论和后续

- candidate-pool 和 corpus-level 的结果共同说明：低比例投毒在检索进入 top-k 后可以显著影响本地 LLM 输出。
- query-first 改进版比旧 instruction-aware 更像真实攻击文本，但强度通常略低于 original。
- 下一步交付层面只剩 GitHub-ready 仓库和 slide deck；研究层面可补 repeated seed、confidence interval 和 minimum poison rate 曲线拟合。